Sécurité des LLM : découverte et retour d'expérience

IANA - 03 Juin 2025

Ressources supplémentaires

- Phare LLM Benchmark, Giskard, 2025
- RealHarm, Giskard, 2025
- learnprompting.org
- Embrace the Red, Blog en ligne
- OWASP Top 10 for LLM Application, OWASP, 2025
- Jailbreaking ChatGPT via Prompt Engineering: An Empirical Study, Liu et al, 2023
- Ignore Previous Prompt: Attach Techniques For Language Models, Perz et al, 2022
- "Do Anything Now" : Characterizing and Evaluating In-The-Wild Jailbreak Prompts on LLM, Shen et al, 2023